

ROBUST ESTIMATORS LAB

Plan de construcción del dashboard interactivo para la tesis

Building Better Estimators: Benchmark-Gated, Regime-Conditional Composite Mean Estimation via Genetic Search

Objetivo operativo: construir una versión estable, didáctica y defendible en 7 días, dejando la segunda semana para grabación, ensayo, integración con la defensa y contingencias.

DECISIÓN DE ARQUITECTURA

R seguirá siendo la fuente científica del experimento completo. Python + Dash + Plotly será la capa de comunicación. El dashboard no reentrenará el GA real: combinará un mini-GA pedagógico con resultados reales precomputados y validados.

Ventana total: 15 días • Construcción: 7 días • Modo de uso: video de 10–15 min + defensa de thesis • Ejecución: local/offline

1. Resumen ejecutivo

El dashboard debe funcionar como un puente visual entre el problema estadístico, la búsqueda genética y la evidencia final. La prioridad no es construir una plataforma genérica ni reproducir días de cómputo en vivo; la prioridad es que en una presentación corta se pueda enseñar qué problema resuelve el GA, cómo navega el simplex, qué encontró realmente y cómo el pipeline decide si una solución merece soporte.

1.1 Alcance obligatorio para la primera versión

- Cuatro capas navegables: 01 Build the problem, 02 GA search, 03 Thesis results y 04 Validation pipeline.
- Capa 1 interactiva con distribución, asimetría, contaminación, escala de outliers, n y comparación de estimadores.
- Capa 2 con mini-GA rápido y paisaje 3D de una rebanada del simplex; la vista debe etiquetarse explícitamente como demostración de baja dimensión.
- Capa 3 alimentada por resultados reales precomputados: régimen, seed, composición del candidato, benchmark, ganancias y categoría de evidencia.
- Capa 4 con fixed-weight validation, estabilidad/CI y evidencia; la batería externa y el Dirichlet abstain audit entran como paneles secundarios si el tiempo lo permite.
- Ejecución 100% local para la defensa, sin depender de internet ni de servicios pagos.

1.2 Fuera de alcance durante esta semana

- Reescribir el GA científico completo de R a Python.
- Reentrenar en vivo el experimento de días de duración.
- Mostrar el simplex de 26 dimensiones como si fuera literalmente un objeto 3D.
- Importar los 245 CSV crudos directamente desde callbacks de la app.
- Autenticación, usuarios, base de datos, nube, despliegue productivo o carga arbitraria de datasets.
- Perfección cosmética antes de que la narrativa y los números estén validados.


1.3 Principios científicos no negociables

- DEMO y REAL RESULTS deben estar visualmente separados. El mini-GA enseña el mecanismo; no se presenta como evidencia de la tesis.

- La superficie 3D se denominará “low-dimensional simplex slice” o “local landscape”, nunca “the full 26-D simplex”.
- Discovery, held-out nomination y fixed-weight confirmation no se mezclarán en una sola etiqueta de “win”.
- Cuando el benchmark es retenido, el dashboard debe mostrarlo con la misma prominencia que un caso favorable al GA.
- El random Dirichlet abstain audit se presenta como auditoría de búsqueda/abstención, no como una nueva confirmación del GA.

2. Narrativa visual del producto

La aplicación debe sentirse como un “Statistical Search Lab”: un entorno de enseñanza donde el usuario primero construye el problema, después observa la búsqueda, luego inspecciona la evidencia real y finalmente recorre la validación. La estética será consistente en las cuatro capas: encabezado oscuro, acento rojo/naranja, controles a la izquierda, visual principal al centro y explicación corta en la parte inferior.



Referencia conceptual - Layer 1: construir el problema y mostrar cómo cambia la posición relativa de los estimadores bajo contaminación.



Referencia conceptual - Layer 2: paisaje geológico 3D del error sobre una rebanada del simplex, con población y trayectoria del GA.

3. Arquitectura técnica

REGLA PRINCIPAL

La app nunca debe depender del árbol completo de resultados durante una presentación. Un script de preparación convierte los resultados crudos a 5–6 archivos compactos optimizados para el dashboard. Así se reduce complejidad, latencia y riesgo de errores de rutas.

3.1 Stack recomendado

Recurso	Uso	Decisión
Python 3.x	Aplicación y mini simulaciones	Motor del dashboard; gratuito.
Dash	UI y callbacks	Navegación por capas, controles y estado.
Plotly	Visualización	3D Mesh3d/Scatter3d, líneas, barras, heatmaps, forest plots.
Pandas	Datos	Carga, filtros, joins y preparación de tablas.
NumPy	Cálculo	Muestreo, pesos, simplex, operaciones vectorizadas.
SciPy	Distribuciones/estadística	Generación pedagógica de distribuciones y utilidades numéricas.
Custom CSS	Diseño	Reproducir la estética limpia del mockup sin depender de servicios externos.
R code + GA_Results	Fuente científica	Definiciones y resultados oficiales; no se reemplazan por Python.

3.2 Fuentes autoritativas ya disponibles

Fuente	Rol	Qué tomamos
Genetic_Algorithms.zip	Código R	03_distributions_params.R, 04_estimators_registry.R, 05_ga_core.R, 07_fitness_objectives.R, 08_LocationEstimators.R.
GA_Results.zip	Resultados	Discovery NEST26, fixed-weight validation, evidence taxonomy, external battery y Dirichlet audit.
Thesis-06Aug-TotalV.zip	Terminología	Título, narrativa y distinción entre discovery, confirmation, audits y external calibration.

3.3 Estructura de carpetas propuesta

```
robust-estimators-dashboard/
├── app.py
├── requirements.txt
├── assets/
│   ├── dashboard.css
│   └── images/
├── pages/
│   ├── build_problem.py
│   ├── ga_search.py
│   ├── thesis_results.py
│   └── validation_pipeline.py
├── src/
│   ├── data_loader.py
│   ├── educational_simulator.py
│   ├── mini_ga.py
│   ├── simplex_landscape.py
│   ├── estimator_functions.py
│   └── ui_components.py
├── scripts/
│   └── prepare_dashboard_data.py
├── data/
│   ├── raw/                # copia mínima de CSV fuente
│   └── dashboard/          # archivos compactos para la app
├── tests/
│   ├── test_simplex.py
│   ├── test_data_integrity.py
│   └── test_reference_cases.py
└── backups/
    ├── screenshots/
    └── demo_recording/
```

4. Diseño funcional por capas

4.1 Layer 01 - Build the problem

Propósito: responder visualmente “¿por qué no basta con elegir un único estimador?”. Esta capa es una simulación pedagógica ligera y no consume resultados del GA.

- Controles: distribution family, skewness/direction, contamination type, contamination rate, outlier scale y sample size.
- Visual central: muestra sintética + densidad + puntos inlier/outlier + líneas de Mean, Median, Trimmed Mean, Huber y Biweight.
- Panel inferior: comparación de estimadores contra la localización verdadera y mensaje “No single estimator is uniformly best”.
- Las opciones deben limitarse a los regímenes que existen en la investigación; no crear una herramienta estadística genérica durante esta semana.
- Tiempo objetivo de respuesta: <0.5 s al redibujar una muestra.

Implementación

1. Traducir únicamente las definiciones necesarias desde 03_distributions_params.R y 08_LocationEstimators.R.

2. Fijar semillas reproducibles para presets de demostración y permitir “Draw sample” con una nueva seed.
3. Implementar 5 estimadores visibles en el MVP; los 26 pueden aparecer como catálogo informativo, pero no necesitan calcularse todos en esta capa.
4. Crear 3 presets para el video: clean/symmetric, moderate contamination y heavy/asymmetric.

4.2 Layer 02 - GA search

Propósito: responder “¿qué está buscando el GA y cómo evoluciona una población?”. Esta capa tiene dos modos claramente diferenciados: DEMO MODE y REAL REFERENCE.

- DEMO MODE: mini-GA de 3–5 estimadores, 20–30 generaciones y población pequeña; debe completarse en segundos y luego reproducirse como animación.
- 3D landscape: usar tres pesos activos y mantener/agrupar el resto. Las coordenadas satisfacen $w_A + w_B + w_C = \text{masa activa}$; la altura Z representa MSE o q95(MSE).
- Render recomendado: Plotly Mesh3d para el terreno triangular; Scatter3d para población, mejor trayectoria y estrella final.
- Paneles auxiliares: convergence over generations y weight evolution.
- REAL REFERENCE: mostrar, junto al demo, el vector final real y la condición real del régimen seleccionado, sin afirmar que la trayectoria animada es la trayectoria exacta del run científico si no fue registrada.

NOTA SOBRE EL HISTORIAL REAL

El código R genera diagnósticos de convergencia internamente (train/validation loss, mutation rate y diversity), pero el GA_Results.zip entregado no contiene archivos de convergence/history. Por eso el MVP no debe inventar una trayectoria histórica. Si se desea una trayectoria real, se agrega como mejora opcional re-ejecutando un único caso instrumentado para exportar checkpoints.

4.3 Layer 03 - Thesis results

Propósito: responder “¿qué encontró realmente el programa de investigación?”. Todo lo visible en esta capa proviene de resultados precomputados.

- Filtros: family, specialist regime, source seed y evidence grade.
- Tarjetas: discovery gate, GA relative improvement, benchmark comparator y final evidence category.
- Composición: barras de los 26 pesos, ordenadas de mayor a menor; opción “top 5 + others”.
- Comparación: MSE/q95 GA vs best benchmark y señal clara de GA candidate / benchmark retained.
- Vista secundaria: mapa por family/regime para mostrar que el método es condicional y no un ganador universal.

4.4 Layer 04 - Validation pipeline

Propósito: responder “¿cómo sé que el candidato no es solo una buena solución del entrenamiento?”. Esta capa debe ser la defensa visual contra overfitting y selección oportunista.

- Funnel principal: Discovery → held-out nomination → frozen weights → fixed-weight validation → evidence taxonomy → external calibration/audits.
- Forest/CI panel: mean_gain y q95_gain con intervalos bootstrap por validation seed o agregado.
- Seed stability: heatmap o matriz de supervivencia.
- Evidence taxonomy: transfer specialist / discovery-supported local candidate / near-gate candidate / benchmark retained/negative-control logic, usando las etiquetas exactas del archivo.
- Panel opcional “External evidence”: resumen compacto de la batería de datasets públicos.
- Panel opcional “Dirichlet abstain audit”: mostrar si una búsqueda aleatoria independiente encontró regiones gate-passing en abstenciones, sin promover esos vectores como descubrimientos confirmados.

5. Inventario de datos y CSV que realmente necesitamos

Para el MVP no cargaremos 245 CSV. Se seleccionarán unas pocas fuentes y se condensarán mediante scripts/prepare_dashboard_data.py. La siguiente matriz define qué entra, dónde entra y cuándo se integra.

Layer	Fuente	Uso	Integración
L1	Sin CSV obligatorio	Generación en vivo con NumPy/SciPy; definiciones auditadas contra R.	Día 2

Layer	Fuente	Uso	Integración
L2	Per-family REGIME_FIRST_WINNER_SUMMARY_seed*.csv	Pesos finales w_* y condiciones de régimen para “real reference”.	Día 3
L2/L3	03.../ combined_final_regime_results_all_rows.csv	Índice compacto de discovery: family, regime, seed, gate_pass, improvements.	Día 1/4
L3	03.../ ga_winner_candidates_for_q1.csv	Casos de discovery que pasaron localmente; útil para ejemplos controlados.	Día 4
L3/L4	05.../ evidence_taxonomy_all_candidates.csv	Fuente principal para categoría final de evidencia y notas interpretativas.	Día 4/5
L3/L4	05.../validated_specialists.csv	Vista corta de los especialistas transferibles/validados según taxonomía actual.	Día 4/5
L4	04.../ post_discovery_fixed_weight_validation_final_decision_table.csv	Decisión de fixed-weight validation por candidato.	Día 5
L4	04.../ post_discovery_fixed_weight_validation_table_bootstrap_ci.csv	CI bootstrap, gains, benchmarks y confirmación por seed/mode.	Día 5
L4	04.../ post_discovery_fixed_weight_validation_stability_summary.csv	Resumen de estabilidad entre seeds y modos.	Día 5
L4 opt.	06.../ external_primary_results_compact.csv	Resumen de resultados de calibración externa por dataset/especialista.	Día 5–6
L4 opt.	06.../ external_taxonomy_summary.csv	Resumen de categorías de evidencia externa.	Día 5–6
L4 opt.	07.../ abstain_audit_summary_by_regime.csv	Resumen por régimen del random Dirichlet abstain audit.	Día 5–6
L4 opt.	07.../ dirichlet_signal_regime_modes.csv	Detalle de señal por validation mode, pass rate y verdict.	Día 5–6

5.1 Archivos derivados que generará el preprocesamiento

Archivo compacto	Grano	Campos clave
dashboard_regimes.csv	1 fila por family/regime/seed	Identificación, condition summary, discovery gate, local gains.
dashboard_weights_long.csv	1 fila por estimator por candidato	distribution, regime, seed, estimator, weight.
dashboard_validation.csv	Fixed-weight + bootstrap agregado	Decisión, mean/q95 gains, CI, validation mode, stability.
dashboard_evidence.csv	Taxonomía final	Evidence grade, interpretive note, audit gains.
dashboard_external.csv	External compact	Dataset/domain, specialist, gains, q/FDR, evidence label.
dashboard_dirichlet.csv	Abstain audit	Regime/mode, random search pass rate, verdict.

5.2 Reglas de integración

- Los CSV compactos se generan una vez antes de ejecutar la app; los callbacks nunca recorren carpetas de raw results.

- Todos los joins usan claves explícitas: distribution + specialist_regime_id + source_seed/validation_id cuando corresponda.
- Los campos w_* de los winner summaries se transforman a formato long para facilitar barras, heatmaps y top-k.
- La app valida al iniciar que cada vector de pesos sea no negativo y sume aproximadamente 1.
- Las etiquetas “discovery”, “fixed-weight”, “external” y “audit” se conservan en una columna stage para evitar mezclar niveles de evidencia.

6. Diseño técnico del simplex geológico 3D

La visualización 3D debe ser una herramienta de enseñanza, no una reconstrucción falsa de 26 dimensiones. El enfoque más robusto para una semana de desarrollo es escoger tres estimadores dominantes de un candidato o preset, fijar la masa del resto y evaluar una malla de combinaciones válidas.

6.1 Construcción de la malla

5. Seleccionar A, B y C (por ejemplo Biweight, Median y Trimean) y definir una masa activa $m = 1 - \text{weight_others}$.
6. Generar una rejilla de pesos no negativos donde $w_A + w_B + w_C = m$.
7. Convertir coordenadas baricéntricas del triángulo a coordenadas cartesianas X/Y para dibujar el simplex.
8. Evaluar el objetivo pedagógico en cada punto; usar $Z = \text{MSE}$ o $Z = q95(\text{MSE})$.
9. Crear Mesh3d con curvas de nivel/colores y superponer población + best path + final star mediante Scatter3d.
10. Permitir rotación, zoom, selector MSE/q95 y generation slider.

6.2 Política de honestidad visual

TEXTO QUE DEBE APARECER EN LA APP

“Visualization of a low-dimensional slice of the full 26-component simplex. The remaining weight mass is fixed/aggregated for interpretability.”

7. Plan de construcción - máximo 7 días

Día	Foco	Trabajo	Definition of done
Día 1	Scope freeze + datos	Crear repo, entorno, requirements, extraer CSV mínimos, implementar prepare_dashboard_data.py, validar claves y pesos.	App abre + data compacta lista.
Día 2	Layer 01	Simulador pedagógico, 5 estimadores, controles, presets, layout y CSS base.	Build the problem funcional.
Día 3	Layer 02	Mini-GA, simplex slice, Mesh3d, población/trajectoria, convergence y weight evolution.	GA search demo completo.
Día 4	Layer 03	Filtros de resultados reales, top weights, gains, benchmarks, evidence grade.	Thesis results conectado a CSV reales.
Día 5	Layer 04	Funnel, final decisions, bootstrap CI, stability; añadir external/Dirichlet si no compromete estabilidad.	Validation pipeline funcional.
Día 6	Integración + diseño	Unificar navegación, tooltips, captions, responsive layout, caché, manejo de errores, presets para video.	Versión visual casi final.
Día 7	QA + congelamiento	Tests de números, pruebas offline, backup, capturas, grabación corta de respaldo, tag v1.0.	Release candidata para presentación.

7.1 Cómo usar los 8 días restantes

Días	Objetivo	Acción
8–9	Ensayo técnico	Recorrer todos los presets; corregir texto, labels y transiciones; bloquear cambios de arquitectura.
10	Guion + grabación	Grabar el video de 10–15 min con un recorrido predeterminado.
11–12	Integración defensa	Decidir 2–3 momentos donde se abre el dashboard; incorporar screenshots de respaldo a las diapositivas.
13	Mock defense	Ensayo completo con cronómetro + preguntas sobre simplex, overfitting y fixed-weight validation.
14	Redundancia	Probar laptop desconectada de internet; copia USB; screenshots/PDF; grabación backup.
15	Buffer	Solo correcciones críticas. No añadir funciones nuevas.

8. Guion de uso para video y defensa

8.1 Recorrido de 10 minutos

Tiempo	Vista	Acción / mensaje
0:00–1:45	Layer 01	Construir una muestra limpia y luego contaminarla. Mostrar cómo Mean se desplaza y robustos permanecen más estables. Mensaje: el ranking depende del régimen.
1:45–4:30	Layer 02	Explicar vector de pesos → simplex → mini-GA. Reproducir 20–30 generaciones en el paisaje 3D. Mostrar selección, crossover, mutation y convergencia.
4:30–7:00	Layer 03	Cambiar a REAL RESULTS. Abrir un caso de discovery favorable y otro donde el benchmark fue retenido. Inspeccionar los pesos.
7:00–9:15	Layer 04	Mostrar que el candidato no se confirma por discovery: frozen weights, fixed-weight validation, CI/seed stability, taxonomía y auditorías.
9:15–10:00	Cierre	Conclusión: “The GA proposes; held-out and fixed-weight evidence decides.”

8.2 Recorrido de 15 minutos para la defensa

Usar el mismo flujo, pero dedicar 1–2 minutos adicionales a la definición matemática de la combinación convexa, explicar que la superficie 3D es una rebanada del simplex de 26 componentes y mostrar un CI/seed-stability panel con más detalle. No navegar libremente: usar presets ensayados.

9. QA, pruebas y criterios de aceptación

Prueba	Criterio	Severidad
Integridad de pesos	Todos los $w \geq 0$; suma = $1 \pm$ tolerancia.	Bloquea release si falla.
Coincidencia de resultados	Valores de gain/benchmark/evidence en dashboard = CSV fuente para 5 casos manuales.	Bloquea release si falla.
Separación de evidencia	Discovery nunca se muestra como fixed-weight confirmed salvo que la taxonomía lo soporte.	Bloquea release si falla.
Simplex 3D	Texto "low-dimensional slice" visible; masa residual documentada.	Bloquea release si falta.
Rendimiento	Filtros precomputados <1 s; demo GA inicia/reproduce sin congelar la interfaz.	Requerido.
Offline	La app funciona con Wi-Fi apagado y rutas relativas.	Requerido para defensa.
Fallback	Screenshots de las cuatro capas + video corto de backup.	Requerido para defensa.

9.1 Casos de referencia que deben probarse

- Caso A: régimen limpio/simétrico para demostrar que el Mean no siempre es malo.
- Caso B: contaminación fuerte/asimétrica para visualizar el desplazamiento del Mean y la estabilidad de robustos.
- Caso C: un discovery GA favorable de NEST26 para enseñar composición y ganancia local.
- Caso D: un candidato que luego queda benchmark_retained en fixed-weight validation para enseñar la diferencia entre nomination y confirmation.
- Caso E: uno de los transfer_specialist de evidence_taxonomy/validated_specialists para mostrar evidencia de transferencia.
- Caso F opcional: un régimen del Dirichlet audit con signal=True para explicar que una abstención puede reflejar una región pequeña que el GA no encontró, sin convertirla en nueva evidencia confirmada.

10. Riesgos y mitigaciones

Riesgo	Qué puede pasar	Mitigación
Scope creep	Se intenta meter los 26 estimadores, 245 CSV y todas las auditorías desde el primer día.	P0/P1/P2; congelar P0 al final del Día 1.
3D engañoso	El jurado interpreta la montaña como el simplex completo.	Etiqueta permanente "low-dimensional slice" + explicación verbal.
Trayectoria inventada	Se dibuja como "real GA path" una animación pedagógica.	Etiquetar DEMO MODE; real data solo para pesos/resultados.
Mismatch R/Python	El simulador educativo usa fórmulas distintas.	Auditar 2–3 muestras con implementación R y tests de referencia.
App lenta	Callbacks leen raw results repetidamente.	Preprocesar; cargar compact CSV una sola vez; cachear.
Fallo en defensa	Internet, navegador o callback falla.	Local/offline + screenshots + video backup + PDF de vistas.
Últimos cambios	Se añaden features a 1–2 días de presentar.	Feature freeze Día 7; días 8–15 solo QA/contenido.

11. Prioridades P0 / P1 / P2

Prioridad	Contenido	Regla
P0 - obligatorio	4 tabs; Layer 1; mini-GA + 3D; resultados reales; fixed-weight/evidence; offline; backup.	Debe estar listo Día 7.
P1 - si P0 está estable	External compact; Dirichlet audit panel; tooltips; presets adicionales; export PNG.	Añadir Día 5–6 solo si no retrasa.
P2 - después de la defensa	Replay de una trayectoria real instrumentada; hosting; más estimadores interactivos; uploader; análisis genérico.	No tocar antes de presentar.

12. Checklist final de entrega

- ☐ requirements.txt instala todo desde cero en un entorno limpio.
- ☐ python app.py abre el dashboard con una única instrucción.
- ☐ No existen rutas absolutas al computador de desarrollo.
- ☐ Los 4 tabs cargan sin errores.
- ☐ Layer 1 tiene al menos 3 presets didácticos.
- ☐ Layer 2 muestra DEMO MODE, simplex slice, población, best path y convergence.
- ☐ Layer 3 coincide con los CSV reales para los casos ensayados.
- ☐ Layer 4 distingue discovery, fixed-weight, evidence taxonomy y audits.
- ☐ El dashboard funciona sin internet.
- ☐ Existe una carpeta backups/ con screenshots y una grabación corta.
- ☐ Existe un guion de 10 min y un recorrido de defensa de 15 min.
- ☐ Feature freeze cumplido al final del Día 7.

RESULTADO ESPERADO AL FINAL DE LA SEMANA

Una herramienta visual estable que explique el estudio sin recalcularlo: el usuario construye un régimen, observa una búsqueda genética simplificada sobre el simplex, consulta resultados reales y sigue la cadena de validación que decide si el benchmark se retiene o si existe soporte para un especialista.

Scope first. Evidence second. Polish third. Freeze after Day 7.